

seqKAN - Resultados de Treino

Fernanda Mickosz Villa Verde

CPE-883 - Aprendizado de Máquina

27 de fevereiro de 2026

Sumário

1 Resumo

2 Metodologia

3 Resultados

- Backbone: **SeqKANSeq** inserido no framework **TSDiffusion**.
- Dinâmica recorrente modelada por KAN com splines univariadas.
- Função de perda multi-termo $\mathcal{L} = \sum_i \lambda_i \mathcal{L}_i$.
- Nos experimentos: termo de reconstrução (MSE) ativo.
- Métrica reportada: MSE (média $\pm$ erro padrão).

1. Estrutura Geral da Célula

A célula implementa, no caso padrão (`concat_mask=False`):

$$h_t = \text{KAN}_{\text{cell}}([x_t, h_{t-1}]), \quad x_t \in \mathbb{R}^C, \quad h_{t-1} \in \mathbb{R}^H$$

Tratamento de máscara no código:

- Se `mask` é fornecida e `concat_mask=False`, o código faz **gating multiplicativo** na entrada:

$$x_t \leftarrow x_t \odot m_t$$

onde m_t é a máscara no tempo t .

- Se `concat_mask=True`, a máscara entra como **feature extra**:

$$x_t^{\text{in}} = [x_t, m_t] \in \mathbb{R}^{2C}$$

e a recorrência passa a ser:

$$h_t = \text{KAN}_{\text{cell}}([x_t, m_t, h_{t-1}]) = \text{KAN}_{\text{cell}}([x_t^{\text{in}}, h_{t-1}])$$

Entrada concatenada geral:

$$z_t = [x_t^{\text{in}}, h_{t-1}] \in \mathbb{R}^{C_{\text{in}}+H}, \quad C_{\text{in}} = \begin{cases} C, & \text{se } \text{concat_mask}=\text{False} \\ 2C, & \text{se } \text{concat_mask}=\text{True} \end{cases}$$

2. Seleção Estrutural Top-k (Condicional)

A esparsidade estrutural é aplicada apenas se:

- `topk.enabled = True`
- `topk.kind = structural`
- `epoch > warmup_epochs`

A máscara é construída a partir de um **score estrutural** por aresta:

$$\text{score}_{ij} = \begin{cases} \|\alpha_{ij}\|_1 \\ \|\alpha_{ij}\|_2 \end{cases}$$

onde α_{ij} são os coeficientes da spline na aresta $i \rightarrow j$.

A nova máscara seleciona as maiores conexões segundo o score, **respeitando a máscara base do ArticleKAN**:

$$M_{ij}^{new} = 1_{\text{top-k}} \cdot 1_{M_{ij}^{base} > 0}$$

3. Separação Estrutural Entrada / Estado (Célula)

No caso da célula recorrente, se definidos:

$$k_x = \text{topk.k_x}, \quad k_h = \text{topk.k_h}$$

a seleção é feita separadamente:

$$h_{t,j} = \sum_{i \in \mathcal{S}_j^{(x)}} s_{ij}(x_{t,i}) + \sum_{l \in \mathcal{S}_j^{(h)}} s_{lj}(h_{t-1,l})$$

com:

$$|\mathcal{S}_j^{(x)}| \leq k_x, \quad |\mathcal{S}_j^{(h)}| \leq k_h$$

Implementação no código:

- Primeiras `input_size` linhas $\Rightarrow$ entradas
- Próximas `hidden_size` linhas $\Rightarrow$ estado
- Seleção $\text{top-}k_x$ e $\text{top-}k_h$ feita por coluna (por neurônio oculto)

Obs.: O número efetivo pode ser menor caso a máscara base já restrinja conexões.

4. Forma da Spline por Aresta

Cada aresta ativa implementa:

$$s_{ij}(u) = \sum_{m=1}^M \alpha_{ijm} B_m(u)$$

onde:

- $B_m(u)$: base B-spline de ordem k
- α_{ijm} : coeficientes aprendidos
- nós definidos por `grid` e `grid_range`
- `grid_eps`: controla mistura entre grid uniforme e adaptativo

O neurônio completo:

$$h_{t,j} = \sum_{i \in S_j} \sum_{m=1}^M \alpha_{ijm} B_m(z_{t,i})$$

5. Propriedade Estrutural

Para cada neurônio:

$$h_{t,j} = \sum_i s_{ij}(z_{t,i})$$

Logo,

$$\frac{\partial^2 h_{t,j}}{\partial z_{t,i} \partial z_{t,r}} = 0 \quad (i \neq r)$$

- Sem interações cruzadas diretas por aresta
- Estrutura aditiva e interpretável

6. Camada de Saída

Para cada saída k , o modelo usa uma head KAN:

$$\text{KAN}_{\text{out}}^{(k)} : \mathbb{R}^H \rightarrow \mathbb{R} \quad (\text{width} = [H, 1])$$

Logo:

$$y_{t,k} = \text{KAN}_{\text{out}}^{(k)}(h_t)$$

Forma estrutural:

$$y_{t,k} = \sum_{j=1}^H M_j^{(k)} r_j^{(k)}(h_{t,j})$$

Se `topk.kind=structural`, aplica-se seleção

$$|\{j : M_j^{(k)} = 1\}| \leq k_{\text{out}}$$

(após warmup, respeitando a máscara base).

7. Interpretação como Sistema Dinâmico

A célula define a recorrência:

$$h_t = F(x_t, h_{t-1})$$

onde $F : \mathbb{R}^{C_{in}+H} \rightarrow \mathbb{R}^H$.

Se $x_t = 0$, obtemos um sistema autônomo:

$$h_t = F(h_{t-1})$$

Logo, o SeqKAN define um:

Sistema Dinâmico Discreto Não Linear

$$h_{t+1} = F(h_t)$$

Características estruturais:

- Dinâmica aditiva (não multiplicativa)
- Não há matriz de recorrência linear W_h
- A não linearidade está distribuída nas arestas
- Interações cruzadas ocorrem apenas via soma no estado

8. Forma Matricial com Máscara Estrutural Dinâmica

Representação com máscara dependente da época:

$$h_{t,j} = \sum_{i=1}^{C_{in}} M_{ij}^{(x)} s_{ij}(x_{t,i}) + \sum_{l=1}^H M_{lj}^{(h)} s_{lj}(h_{t-1,l})$$

onde:

- M é atualizada dinamicamente após warmup
- A seleção pode ser:
 - **per-output**: top-k por coluna
 - **global**: top-k global na camada
- Na célula: possível separação explícita entre k_x e k_h

A máscara estrutural não altera os coeficientes, apenas zera conexões fora do top-k.

9. Implicações Estruturais

- Funções explícitas por feature (splines univariadas por aresta)
- Controle estrutural via top-k (opcional)
- Sistema dinâmico não linear com esparsidade estrutural
- Ausência de interação cruzada direta dentro da aresta KAN
- Separação explícita entre contribuição de x_t e memória h_{t-1}

Comparação Final – Test Results

Modelo	Loss (train)	Teste MSE ($\mu \pm SE$)
TSDF_GRU (hidden 11 * 32)	0.220276	0.178609 $\pm$ 0.003885
TSDF_GRU (hidden 24)	0.255656	0.198943 $\pm$ 0.004269
TSDF_SeqKANSeq (grid 8/hidden 24/k_x 6 k_h 6 k_out 8)	0.257547	0.200799 $\pm$ 0.004295
TSDF_SeqKANSeq (grid 8/hidden 64/k_x 6 k_h 15 k_out 20)		$\pm$
TSDF_SeqKANSeq		$\pm$
TSDF_SeqKANSeq		$\pm$
TSDF_SeqKANSeq		$\pm$
TSDF_SeqKANSeq		$\pm$

Comparação Final por Grupos – Test Results

Modelo	MSE Grupo 0 ($\mu \pm SE$)	Grupo 1 ($\mu \pm SE$)
TSDF_GRU (hidden 11 * 32)	0.168903 $\pm$ 0.003818	0.266408 $\pm$ 0.017820
TSDF_GRU (hidden 24)	0.185448 $\pm$ 0.004092	0.321018 $\pm$ 0.021071
TSDF_SeqKANSeq (grid 8/hidden 24/k_x 6 k_h 6 k_out 8)	0.187149 $\pm$ 0.004091	0.324272 $\pm$ 0.021596
TSDF_SeqKANSeq (grid 8/hidden 64/k_x 6 k_h 15 k_out 20)	$\pm$	$\pm$
TSDF_SeqKANSeq	$\pm$	$\pm$
TSDF_SeqKANSeq	$\pm$	$\pm$
TSDF_SeqKANSeq	$\pm$	$\pm$
TSDF_SeqKANSeq	$\pm$	$\pm$

SeqKANSeq implementa:

$$h_t = F(x_t, h_{t-1})$$

com:

- Não linearidade distribuída nas arestas (B-splines)
- Recorrência explícita sem gates multiplicativos
- Esparsidade estrutural opcional via top-k
- Estrutura aditiva interpretável

Resultados mostram desempenho comparável ao GRU, com maior controle estrutural.