

seqKAN - Resultados de Treino

Fernanda Mickosz Villa Verde

CPE-883 - Aprendizado de Máquina

26 de fevereiro de 2026

1 Resumo

2 Metodologia

- Objetivo: avaliar o modelo seqKAN para reconstrução de séries temporais industriais buscando maior interpretação.
- seqKAN: modelo baseado em splines B-spline para modelar relações não lineares e temporais.
- Metodologia: treino supervisionado com loss de reconstrução, usando métricas MSE e SE.

1. Estrutura Geral da Célula

A célula implementa:

$$h_t = \text{KAN}_{\text{cell}}([x_t, h_{t-1}])$$

onde:

$$x_t \in \mathbb{R}^C, \quad h_{t-1} \in \mathbb{R}^H$$

Entrada concatenada:

$$z_t = [x_t, h_{t-1}] \in \mathbb{R}^{C+H}$$

2. Forma Funcional por Neurônio

Para cada neurônio oculto $j \in \{1, \dots, H\}$:

$$h_{t,j} = \sum_{i \in \mathcal{S}_j} s_{ij}(z_{t,i})$$

onde:

$$\mathcal{S}_j \subset \{1, \dots, C + H\}$$

$$|\mathcal{S}_j| = k_x + k_h$$

Cada $s_{ij}(\cdot)$ é uma B-spline univariada aprendida.

3. Separação Estrutural Entrada / Estado

Imposição estrutural:

$$\mathcal{S}_j = \mathcal{S}_j^{(x)} \cup \mathcal{S}_j^{(h)}$$

com:

$$|\mathcal{S}_j^{(x)}| = k_x \quad |\mathcal{S}_j^{(h)}| = k_h$$

Portanto:

$$h_{t,j} = \sum_{i \in \mathcal{S}_j^{(x)}} s_{ij}^{(x)}(x_{t,i}) + \sum_{l \in \mathcal{S}_j^{(h)}} s_{lj}^{(h)}(h_{t-1,l})$$

4. Forma da Spline por Aresta

Cada aresta ativa implementa:

$$s_{ij}(u) = \sum_{m=1}^M \alpha_{ijm} B_m(u)$$

onde:

- $B_m(u)$: base B-spline de ordem k
- α_{ijm} : coeficientes aprendidos
- nós definidos por `grid` e `grid_range`

O neurônio completo:

$$h_{t,j} = \sum_{i \in \mathcal{S}_j} \sum_{m=1}^M \alpha_{ijm} B_m(z_{t,i})$$

5. Propriedade Estrutural Importante

Como as funções são univariadas e somadas:

$$\frac{\partial^2 h_{t,j}}{\partial z_{t,i} \partial z_{t,r}} = 0 \quad \text{para } i \neq r$$

Implica:

- Não há interação cruzada direta entre variáveis dentro do mesmo neurônio.
- A interação ocorre apenas via soma no nível do estado.

6. Camada de Saída

Para cada saída $y_{t,k}$:

$$y_{t,k} = \sum_{j \in \mathcal{T}_k} r_{jk}(h_{t,j})$$

com:

$$|\mathcal{T}_k| = k_{out}$$

Cada r_{jk} também é uma spline univariada.

7. Interpretação como Sistema Dinâmico

A célula define a recorrência:

$$h_t = F(x_t, h_{t-1})$$

onde $F : \mathbb{R}^{C+H} \rightarrow \mathbb{R}^H$.

Se $x_t = 0$, obtemos um sistema autônomo:

$$h_t = F(h_{t-1})$$

Logo, o SeqKAN define um:

Sistema Dinâmico Discreto Não Linear

$$h_{t+1} = F(h_t)$$

Características estruturais:

- Dinâmica aditiva (não multiplicativa)
- Não há matriz de recorrência linear W_h
- A não linearidade está distribuída nas arestas
- Interações cruzadas ocorrem apenas via soma no estado

8. Forma Matricial com Máscara Estrutural

Representação equivalente:

$$h_{t,j} = \sum_{i=1}^C M_{ij}^{(x)} s_{ij}(x_{t,i}) + \sum_{l=1}^H M_{lj}^{(h)} s_{lj}(h_{t-1,l})$$

onde:

- M é a máscara estrutural top-k
- Cada neurônio possui exatamente $k_x + k_h$ conexões ativas

9. Implicações Estruturais

- Modelo interpretável (funções explícitas por feature)
- Controle estrutural via top-k
- Sistema dinâmico não linear esparsos
- Interação entre variáveis ocorre apenas via estado
- Separação clara entre contribuição de x_t e memória h_{t-1}

A célula SeqKAN implementa:

$$h_t = F(x_t, h_{t-1})$$

com:

- Funções univariadas spline
- Esparsidade estrutural controlada
- Dinâmica recorrente explícita
- Alto grau de interpretabilidade