

TSDF_seqKANSeq (KAN + saída linear)

Resultados e Estrutura do Treino

Fernanda Mickosz Villa Verde

CPE-883 - Aprendizado de Máquina

5 de março de 2026

- 1 Resumo
- 2 Metodologia
- 3 Resultados
- 4 Explicabilidade e Evidências

- Modelo: **TSDF_seqKANSeq** com **KAN_cell** + **head linear** e **rebuild** (reconstrução direta).
- Entrada observada por tempo:

$$x_t \in \mathbb{R}^C, \quad \text{mask}_t \in \{0, 1\}^C$$

- A máscara modula a memória:

$$\gamma_t = W(1 - \text{mask}_t) + b, \quad m_t = \gamma_t \odot h_{t-1}$$

- Atualização recorrente:

$$h_t = \text{KAN}_{\text{cell}}([x_t, h_{t-1}, m_t])$$

- A saída é a reconstrução do próprio x_t :

$$\hat{x}_t = W_{\text{out}} h_t + b_{\text{out}}$$

- Loss no modo atual: reconstrução (MSE) com termo de difusão opcional.

- O modelo combina **entrada atual** com **memória passada** para reconstruir a série.
- A máscara indica faltantes e **modula** a memória: m_t reforça/atenua partes de h_{t-1} .
- A célula recorrente **junta** x_t , h_{t-1} e m_t para produzir o novo estado h_t .
- A saída $\hat{x}_t$ é lida do estado via **head linear** ($W_{out}h_t + b_{out}$).
- No wrapper TSDF_seqKANSeq: `direct_x=True`, sem `bi_gru`, sem cabeças de miss/VAE e sem `log_likelihood`.

ArticleKAN: splines por conexão

- O backbone usa o **ArticleKAN**: cada aresta $i \rightarrow j$ aprende uma spline univariada.
- Forma geral:

$$y_j = \sum_i f_{ij}(x_i), \quad f_{ij} \text{ spline 1D}$$

- Cada spline é definida por:
 - **grid** (nós) e ordem k
 - coeficientes das bases B-spline
- Vantagens:
 - interpretabilidade por conexão (curva f_{ij})
 - controle estrutural da malha de conexões
 - não-linearidade local por partes

Visão geral: SeqKAN recorrente

Arquitetura por passo de tempo t (com $H = \text{hidden_size}$)

$$\begin{aligned}\gamma_t &= W(1 - \text{mask}_t) + b \in \mathbb{R}^H \\ m_t &= \gamma_t \odot h_{t-1} \in \mathbb{R}^H \\ h_t &= \text{KAN}_{\text{cell}}([x_t, h_{t-1}, m_t]) \in \mathbb{R}^H \\ \hat{x}_t &= W_{\text{out}}h_t + b_{\text{out}} \in \mathbb{R}^C\end{aligned}$$

- **KAN_cell**: recebe um vetor de dimensão $C + 2H$ (x_t , h_{t-1} e m_t) e atualiza a memória recorrente.
- **Head linear**: reconstrução $\hat{x}_t$ a partir do estado.

Máscara $\rightarrow$ memória modulada

A máscara gera um gate em hidden via projeção linear:

$$\gamma_t = W(1 - \text{mask}_t) + b$$

e modula o estado anterior:

$$m_t = \gamma_t \odot h_{t-1}.$$

Este termo m_t entra como **terceiro bloco** da entrada da célula:

$$h_t = \text{KAN}_{\text{cell}}([x_t, h_{t-1}, m_t]).$$

Top-k: esparsidade por ativação (k_h)

- Existe top-k **por ativação** aplicado ao vetor h_t :

$$h_t \leftarrow \text{TopK}(h_t; k_h)$$

mantendo apenas as k_h maiores componentes em magnitude ($|\cdot|$) por amostra/tempo.

- Warmup: o top-k só entra quando `current_epoch > warmup_epochs`.
- **Bottleneck dinâmico** no hidden, reduzindo complexidade e aumentando interpretabilidade por dimensão ativa.

- Perda efetiva no modo KAN-only:

$$\mathcal{L} \approx \lambda_0 \mathcal{L}_{recon} + \lambda_1 \mathcal{L}_{noise}$$

- $\mathcal{L}_{recon}$: erro de reconstrução de $\hat{x}$ (MSE mascarado por observações).
- $\mathcal{L}_{noise}$: predição de ruído de difusão, usada apenas quando $\lambda_1 > 0$.
- Restrições impostas no construtor: `direct_x=True`, `static_dim=0`, `status_dim=0`, `log_likelihood=False`, e $\lambda_3 = \lambda_4 = \lambda_5 = 0$.

Modelo	Loss (train)	Teste MSE ($\mu \pm \text{SE}$)
TSDF_GRU ($H=352$)	0.191	0.146 ± 0.003
TSDF_SeqKANSeq ($H=24$)	0.215	0.159 ± 0.003
TSDF_GRU ($H=24$)	0.213	0.163 ± 0.003
TSDF_SeqKANSeq ($H=352$)	0.229	0.169 ± 0.004
TSDF_SeqKANSeq ($H=8$)	0.237	0.173 ± 0.004
TSDF_GRU ($H=8$)	0.245	0.178 ± 0.004

Comparativo MSE por H

H	seqKAN - MSE	GRU - MSE
8	0.173 ± 0.004	0.178 ± 0.004
24	0.159 ± 0.003	0.163 ± 0.003
352	0.169 ± 0.004	0.146 ± 0.003

Sparsidade Estrutural (SE) dos resultados mais recentes

Modelo	SE (arestas ativas $> \epsilon$)	SE (pesos ativos $> \epsilon$)	SE (hiddens ativos $> \epsilon$)	SE (compress q_{90})
seqKAN	0.7179	—	—	—
GRU	—	0.9159	1.0000	0.9000

Fonte: explainability_v2_main.csv (timestamp mais recente: 2026-03-04 12:23).

Obs.: no seqKAN, $0.7179 = 1 - \text{sparsity}_{\epsilon}$ (com $\text{sparsity}_{\epsilon} = 0.2821$).

Estabilidade de Explainability (EA)

Método (EA)	seqKAN ρ (média $\pm$ sd)	GRU ρ (média $\pm$ sd)	Δ (seqKAN–GRU)
Permutation Window	0.9159 $\pm$ 0.1141	0.7953 $\pm$ 0.1208	+0.1206
Integrated Gradients (IG)	1.0000 $\pm$ 0.0000	0.9994 $\pm$ 0.0023	+0.0006
Grad $\times$ Input	0.5008 $\pm$ 0.0006	0.5007 $\pm$ 0.0006	+0.0000

Regras de Domínio (AD)

Modelo	AD pass rate	Regras aprovadas
seqKAN	0.25	1/4
GRU	0.50	2/4

Nos sanity checks de forma (monotonicidade/saturação/consistência de sinal), a GRU apresentou maior taxa de aprovação, indicando necessidade de constraints/regularização de forma para consolidar o seqKAN em requisitos mandatórios de engenharia.

Interpretabilidade no KAN: leitura por aresta (edge-wise)

- Em KAN, cada conexão $i \rightarrow j$ é uma função univariada aprendida $f_{ij}(\cdot)$ (spline):

$$y_j = \sum_i f_{ij}(u_i)$$

- No modelo atual existe um conjunto de funções spline inspecionáveis:
 - $\text{KAN}_{cell}: f_{j \rightarrow r}^{cell}([x, h, m]_{t,j})$ (dinâmica no hidden)
 - Saída linear: contribuição por peso $W_{out}(c, j) \cdot h_{t,j}$ (hidden $\rightarrow$ feature reconstruída)
- Estratégia de explicação recomendada: selecionar arestas mais relevantes (por $|\text{coef}|$ ou contribuição) e plotar suas splines.

Evidência visual dos caminhos




Tabela 2. Pontos-chave das splines e contribuição no output

Caminho (feature→hidden→output)	$f(-3)$	$c(-3)$	$f(\approx 0)$	$c(\approx 0)$	$f(3)$	$c(3)$	$\Delta c = c(3) - c(-3)$	Sinal do efeito
$i=8 \rightarrow j=15 \rightarrow m=2$	-0.669	-0.469	0.022	0.015	0.404	0.283	+0.752	positivo (forte)
$i=6 \rightarrow j=17 \rightarrow m=2$	-0.148	0.063	0.049	-0.021	0.577	-0.247	-0.310	negativo (moderado)
$i=4 \rightarrow j=9 \rightarrow m=4$	-0.294	-0.128	-0.005	-0.002	0.590	0.257	+0.384	positivo (moderado)

Conclusão (alinhada ao código atualizado)

O TSDF_seqKANSeq (KAN + saída linear) implementa reconstrução recorrente com KAN_cell e head linear:

$$m_t = \gamma_t \odot h_{t-1},$$

$$h_t = \text{KAN}_{\text{cell}}([x_t, h_{t-1}, m_t]),$$

$$\hat{x}_t = W_{\text{out}} h_t + b_{\text{out}}$$

- Não-linearidade distribuída nas arestas (B-splines do ArticleKAN) na **célula**; saída é **linear**.
- Máscara atua como **condicionamento** via m_t (memória modulada).
- Esparsidade: **Top-k por ativação** em h_t (parâmetro k_h); top-k estrutural está desligado.
- Difusão é **opcional** ($\lambda_1 > 0$); no modo padrão, a reconstrução domina.