

TSDF_seqKANSeq (KAN-only)

Resultados e Estrutura do Treino

Fernanda Mickosz Villa Verde

CPE-883 - Aprendizado de Máquina

1 de março de 2026

Sumário

1 Resumo

2 Metodologia

3 Resultados

Resumo (compatível com o código atual)

- Modelo: **TSDF_seqKANSeq** em modo **KAN-only**: sem MLP decoder, sem VAE, sem miss-head, sem status/static.
- Entrada efetiva do backbone (por timestep): **concatenação explícita**

$$s_t = [x_t, m_t] \in \mathbb{R}^{2C}$$

onde m_t é máscara feature-wise (1=observado, 0=ausente). No código: $h = \text{cat}([x, \text{mask}], -1)$.

- Célula recorrente: **SeqKANSeq** computa

$$h_t = \text{KAN}_{\text{cell}}([s_t, h_{t-1}]), \quad \hat{x}_t = \text{KAN}_{\text{out}}(h_t)$$

- Treino supervisionado por reconstrução (MSE). O bloco de difusão injeta ruído em **[x,mask]** (opcionalmente ruído também na máscara).

KAN: ideia central

- Em redes usuais (MLP), cada neurônio combina entradas por pesos lineares:

$$y_j = \sum_i w_{ij} z_i$$

- No **KAN**, cada conexão $i \rightarrow j$ é uma **função univariada aprendida**:

$$y_j = \sum_i f_{ij}(z_i)$$

- Consequências: estrutura **aditiva**, maior **interpretabilidade por conexão** e controle direto do grafo.

Intuição

Troca “peso” por “função 1D” em cada aresta.

KAN_cell e KAN_out: o que são esses dois blocos?

- O SeqKANSeq é composto por dois módulos KAN com papéis diferentes:
 - **KAN_cell (transição do estado)**: atualiza a memória do modelo.
 - **KAN_out (leitura/saída)**: transforma a memória em saída/reconstrução.
- **KAN_cell** implementa a dinâmica recorrente:

$$h_t = \text{KAN}_{cell}([s_t, h_{t-1}]), \quad s_t = [x_t, m_t]$$

Intuição: “como a entrada atual e o estado anterior se combinam para formar o novo estado”.

- **KAN_out** implementa o head de reconstrução:

$$\hat{x}_t = \text{KAN}_{out}(h_t)$$

Intuição: “como ler o estado oculto para reconstruir as features”.

- Ambos são **KAN**: em vez de pesos lineares, usam somas de **funções univariadas por conexão**, o que facilita controle estrutural (ex.: Top-k) e interpretabilidade.
- Diferença para GRU/LSTM: não há gates multiplicativos; a não linearidade está nas **funções das conexões**.

O que são as splines no KAN

- No KAN, cada conexão $i \rightarrow j$ aprende uma função univariada $f_{ij}(\cdot)$. Em vez de escolher uma ativação fixa (ReLU, tanh), o modelo **aprende o formato da curva**.
- Essa função é parametrizada como uma **spline**: uma curva **por partes** definida em intervalos do eixo- x .
- O domínio é dividido em **nós** (grid). Em cada intervalo entre nós, a spline usa um polinômio simples, mas a junção entre intervalos é feita de forma **suave** (continuidade).
- Intuição prática:
 - mais nós $\Rightarrow$ mais flexibilidade para capturar não linearidades;
 - menos nós $\Rightarrow$ função mais simples e mais estável.
- Interpretabilidade: ao inspecionar a curva $f_{ij}(u)$, vemos **como uma entrada específica influencia** o neurônio de saída.

Splines no KAN: função aprendida por conexão

- No KAN, cada conexão $i \rightarrow j$ aprende uma função univariada

$$f_{ij} : \mathbb{R} \rightarrow \mathbb{R}, \quad u \mapsto f_{ij}(u)$$

- Essa função é parametrizada como uma **B-spline** (combinação linear de bases):

$$f_{ij}(u) = \sum_{m=1}^M \alpha_{ijm} B_m^{(k)}(u)$$

onde:

- $B_m^{(k)}(u)$ são funções base B-spline de ordem k (grau $k - 1$),
- α_{ijm} são coeficientes aprendidos,
- M depende do número de nós (grid) e da ordem k .
- Intuição: o modelo não escolhe uma ativação fixa; ele aprende a **curva** f_{ij} em cada aresta.

Nós, suporte local e suavidade das B-splines

- A spline é definida em relação a uma sequência de nós

$$t_0 \leq t_1 \leq \dots \leq t_K$$

(o **grid** cobre um intervalo de interesse, e.g. $[a, b]$).

- Cada base B-spline tem **suporte local**:

$$B_m^{(k)}(u) = 0 \quad \text{fora de } [t_m, t_{m+k}]$$

Logo, ajustar α_{ijm} afeta f_{ij} apenas em uma região do eixo- u .

- **Suavidade**: uma B-spline de ordem k (grau $k - 1$) é tipicamente

$$f_{ij} \in C^{k-2}$$

ou seja, tem continuidade de derivadas até ordem $k - 2$ (exceto em casos de nós repetidos).

- Trade-off:
 - mais nós $\Rightarrow$ maior flexibilidade (captura não linearidades finas),
 - menos nós $\Rightarrow$ função mais simples/regularizada.

Esparsidade Estrutural (Top-k) por neurônio

- Para aumentar **interpretabilidade** e **controle estrutural**, aplicamos **Top-k** nas conexões do KAN.
- Como o KAN é aditivo por arestas, cada neurônio j recebe contribuições por conexões $i \rightarrow j$:

$$y_j = \sum_i f_{ij}(z_i)$$

- Com Top-k **por neurônio**, mantemos apenas as k conexões mais relevantes **para cada neurônio** j :

$$y_j = \sum_{i \in \mathcal{S}_j} f_{ij}(z_i), \quad |\mathcal{S}_j| \leq k$$

- Interpretação: cada neurônio passa a depender de um **conjunto pequeno e estável de entradas**, o que simplifica a leitura do grafo e reduz conexões fracas/ruidosas.

Onde aplicamos

Na célula recorrente ($[x_t, m_t]$ e h_{t-1}) e/ou no head de saída ($h_t \rightarrow \hat{x}_t$).

Top-k na célula recorrente (entrada vs memória)

- Na atualização do estado, o SeqKANSeq combina **entrada** e **memória**:

$$h_t = \text{KAN}_{cell}([x_t, m_t, h_{t-1}])$$

- Com **Top-k por neurônio**, cada neurônio oculto seleciona apenas um número limitado de conexões relevantes.
- Essa seleção pode ser feita **separando as fontes**:
 - até k_x conexões vindas da **entrada** ($[x_t, m_t]$),
 - até k_h conexões vindas da **memória** (h_{t-1}),
 - (opcional) tratar a **máscara** m_t separadamente para não competir com as features de x_t .
- Intuição: controlar **quantas variáveis do instante** e **quanta memória passada** cada neurônio pode usar.

Top-k no head de saída (reconstrução)

- A reconstrução é produzida por um head (KAN) que lê o estado:

$$\hat{x}_t = \text{KAN}_{out}(h_t)$$

- Com **Top-k por saída**, cada componente $\hat{x}_{t,k}$ depende de apenas algumas dimensões de h_t : isso limita quantos estados ocultos influenciam cada feature reconstruída.
- Em todos os casos, o Top-k atua como **máscara estrutural**: ele **remove conexões** sem mudar a forma das funções nas conexões mantidas.
- A seleção respeita as conexões permitidas pelo modelo-base (máscara estrutural inicial).

8. Forma da spline por aresta (KAN do artigo)

Cada aresta ativa implementa:

$$s_{ij}(u) = \sum_{m=1}^M \alpha_{ijm} B_m(u)$$

onde:

- B_m : base B-spline (ordem k)
- α_{ijm} : coeficientes aprendidos (armazenados em `coef`)
- nós definidos por `grid`, `grid_range` e `grid_eps`
- a máscara estrutural atua zerando arestas: $s_{ij}(\cdot) = 0$ se $M_{ij} = 0$

9. Observação estrutural (interpretação)

A estrutura do neurônio é aditiva:

$$h_{t,j} = \sum_{q \in \mathcal{S}_j} s_{qj}(v_{t,q}), \quad v_t = [x_t, m_t, h_{t-1}]$$

Logo, não existem termos multiplicativos do tipo $z_i z_r$ dentro da mesma aresta; interações cruzadas só emergem via soma no estado e por camadas subsequentes.

Comparação Final – Test Results

Modelo	Loss (train)	Teste MSE ($\mu \pm \text{SE}$)
TSDF_GRU (hidden 8)	0.189331	0.147292 $\pm$ 0.003195
TSDF_GRU (hidden 24)	0.181741	0.145757 $\pm$ 0.003234
TSDF_GRU (hidden 11 * 32)	0.184935	0.145667 $\pm$ 0.003229
TSDF_SeqKANSeq (grid 8 / hidden 8 / $k_x=4$ $k_m=2$ $k_h=4$ $k_{out}=4$)	0.250516	0.175399 $\pm$ 0.003855
TSDF_SeqKANSeq (grid 8 / hidden 24 / $k_x=4$ $k_m=2$ $k_h=6$ $k_{out}=8$)	0.220477	0.163581 $\pm$ 0.003494
TSDF_SeqKANSeq (grid 8 / hidden 11*32 / $k_x=4$ $k_m=2$ $k_h=88$ $k_{out}=117$)	(preencher)	(preencher)

Comparação Final por Grupos – Test Results

Modelo	MSE Grupo 0 ($\mu \pm \text{SE}$)	MSE Grupo 1 ($\mu \pm \text{SE}$)
TSDF_GRU (hidden 8)	(preencher)	(preencher)
TSDF_GRU (hidden 24)	(preencher)	(preencher)
TSDF_GRU (hidden 11 * 32)	(preencher)	(preencher)
TSDF_SeqKANSeq (grid 8 / hidden 8 / $k_x=4$ $k_m=2$ $k_h=4$ $k_{out}=4$)	(preencher)	(preencher)
TSDF_SeqKANSeq (grid 8 / hidden 24 / $k_x=4$ $k_m=2$ $k_h=6$ $k_{out}=8$)	(preencher)	(preencher)
TSDF_SeqKANSeq (grid 8 / hidden 11*32 / $k_x=4$ $k_m=2$ $k_h=88$ $k_{out}=117$)	(preencher)	(preencher)

Conclusão (alinhada ao código)

O TSDF_seqKANSeq (KAN-only) implementa:

$$h_t = F([x_t, m_t], h_{t-1}), \quad \hat{x}_t = G(h_t)$$

com:

- Não linearidade distribuída nas arestas (B-splines do ArticleKAN)
- Recorrência explícita sem gates multiplicativos (estilo GRU/LSTM)
- Top-k estrutural opcional aplicado à **máscara de conexões** após warmup
- Separação explícita do top-k na célula: x vs m vs h_{t-1} (quando configurado)

Resultados mostram gap em relação ao GRU nas configs atuais, mas com maior controle estrutural e interpretabilidade por aresta.